

Aufgabe 5.1 [Kontextfreie Grammatiken konstruieren]

5 Punkte

In dieser Aufgabe sollen Sie kontextfreie Grammatiken konstruieren.

- Gesucht ist eine kontextfreie Grammatik G für die Sprache L , welche genau die Wörter enthält, die mit einer (möglicherweise leeren) Folge von a beginnen, gefolgt von doppelt oder genau halb so vielen b wie a . Zum Beispiel enthält L die Wörter $aabbbb$ und $aaaaaabb$. **(2 Punkte)**
- Geben Sie eine kontextfreie Grammatik für das JSON (JavaScript Object Notation) Datenaustauschformat an. Sie finden unter <https://json.org> die Spezifikation des Formats. Wir beschränken uns auf eine Abstraktion, so dass wir Zeichenketten (Strings) durch das Symbol `str` und Zahlen durch das Symbol `num` darstellen.

Somit lautet unser Alphabet

$$\Sigma = \{[,], \{, \}, ., :, \text{str}, \text{num}, \text{true}, \text{false}, \text{null}\}.$$

Geben Sie eine kontextfreie Grammatik an, welche genau die gültigen JSON *values* beschreibt. **(3 Punkte)**

Lösung:

- Die kontextfreie Grammatik G könnte folgendermaßen aussehen:

$$\begin{array}{lcl} S & \rightarrow & A \mid B \\ A & \rightarrow & aaAb \mid \varepsilon \\ B & \rightarrow & aBbb \mid \varepsilon \end{array}$$

Die erste Regel entspricht der Auswahl zwischen doppelt oder genau halb so vielen a wie b . Denn mit der zweiten Produktion erzeugen wir das leere Wort oder für jedes b zwei a . Wohingegen wir mit der dritten Produktion das leere Wort oder für jedes a zwei b erzeugen. Dies geschieht jeweils in der benötigten Reihenfolge, d.h. as vor bs .

- Eine mögliche Lösung ist folgende kontextfreie Grammatik wobei V das Startsymbol ist:

$$\begin{array}{lcl} V & \rightarrow & \text{str} \mid \text{num} \mid \text{true} \mid \text{false} \mid \text{null} \mid O \mid A \\ P & \rightarrow & \text{str}:V \mid \text{str}:V,P \\ O & \rightarrow & \{P\} \mid \{\} \\ A' & \rightarrow & V \mid V,A' \\ A & \rightarrow & [A'] \mid [] \end{array}$$

Vom Startsymbol V können wir die verschiedenen JSON values ableiten. Wobei wir das Symbol O für Objekte und A für Arrays nutzen. Objekte bestehen aus geschweiften Klammern sowie darin einer (möglicherweise leeren) Liste von jeweils `str:` und einer Value. Wir nutzen die zweite Produktion, um entweder Objekte mit nur einem `str:` Value oder mehreren zu erzeugen, wobei in diesem Fall die Einträge paarweise durch ein Komma getrennt werden. Ähnlich gehen wir für Arrays mit den letzten beiden Regeln vor.

Aufgabe 5.2 [Chomsky-Normalform]**7 Punkte**

In dieser Aufgabe soll der Algorithmus, der eine kontextfreie Grammatik in die Chomsky-Normalform bringt, angewendet werden. Dabei soll in den folgenden Teilaufgaben einzelne Teilschritte des Algorithmus (CNF1 – CNF5) mit der jeweils angegebenen Grammatik durchgeführt werden.

a) **CNF1:** Gegeben sei die kontextfreie Grammatik G_0 mit den folgenden Regeln:

$$\begin{array}{lcl} S & \rightarrow & Bb \mid Da \mid E \\ A & \rightarrow & aAB \mid aA \mid C \\ B & \rightarrow & bBD \mid Bb \mid C \\ C & \rightarrow & c \mid D \mid B \\ D & \rightarrow & a \\ E & \rightarrow & Ed \end{array}$$

Geben Sie die Grammatik nach Entfernen der nicht erzeugenden und nicht erreichbaren Variablen an. Beschreiben Sie Ihr Vorgehen, die Zwischenschritte und geben Sie die Menge V_e und den Erreichbarkeitsgraphen an. **(2 Punkte)**

b) **CNF2/CNF3:** Gegeben sei die kontextfreie Grammatik G_1 mit den folgenden Regeln:

$$\begin{array}{lcl} S & \rightarrow & BBb \mid bc \\ A & \rightarrow & B \mid Aa \mid c \\ B & \rightarrow & BABAa \mid Bb \mid C \\ C & \rightarrow & c \mid A \mid B \end{array}$$

Geben Sie die Grammatiken nach Trennen der Variablen und Terminalsymbole (CNF2) an und verkürzen Sie dann die rechten Seiten (CNF3). Beschreiben Sie Ihr Vorgehen und geben Sie die Zwischenschritte an. **(2 Punkte)**


c) **CNF4/CNF5:** Gegeben sei die kontextfreie Grammatik G_3 mit den folgenden Regeln:

$$\begin{array}{lcl} S & \rightarrow & W_b A \mid BW_c \\ A & \rightarrow & B \mid AW_a \mid W_c \\ B & \rightarrow & BW_a \mid BW_b \mid C \\ C & \rightarrow & W_c \mid A \mid B \mid \varepsilon \\ W_a & \rightarrow & a \\ W_b & \rightarrow & b \\ W_c & \rightarrow & c \end{array}$$

Geben Sie die Menge V' an und entfernen Sie die ε -Regeln (CNF4). Entfernen Sie anschließend die Einheits-Regeln (CNF5). Geben Sie die Zwischenschritte und die Menge U an. **(3 Punkte)**

Lösung:

- a) Es werden zuerst die nicht erzeugenden Variablen entfernt und für die resultierende kontextfreie Grammatik der Erreichbarkeitsgraph konstruiert. Es ist $V_e = \{S, A, B, C, D\}$. Die Variable E ist nicht erzeugend und wird deshalb weggelassen. Erreichbarkeitsgraph:



Symbol A kann vom Startsymbol aus nicht erreicht werden. Die kontextfreie Grammatik nach Entfernen der nicht erzeugenden und nicht erreichbaren Variablen (CNF1):

$$\begin{array}{lcl}
 S & \rightarrow & Bb \mid Da \\
 B & \rightarrow & bBD \mid Bb \mid C \\
 C & \rightarrow & c \mid D \mid B \\
 D & \rightarrow & a
 \end{array}$$

- b) Wir ersetzen die Terminalsymbole in rechten Regelseiten durch neue Variablen, fügen die benötigten Regeln für die Terminalsymbole ein und erhalten damit die folgende kontextfreie Grammatik (CNF2):

$$\begin{array}{lcl}
 S & \rightarrow & BBW_b \mid W_bW_c \\
 A & \rightarrow & B \mid AW_a \mid W_c \\
 B & \rightarrow & BABAW_a \mid BW_b \mid C \\
 C & \rightarrow & W_c \mid A \mid B \\
 W_a & \rightarrow & a \\
 W_b & \rightarrow & b \\
 W_c & \rightarrow & c
 \end{array}$$

Anschließend verkürzen wir die rechten Seiten mit Algorithmus CNF3. Die kontextfreie Grammatik nach Verkürzen der rechten Seiten:

$$\begin{array}{lcl}
 S & \rightarrow & BS_1 \mid W_bW_c \\
 S_1 & \rightarrow & BW_b \\
 A & \rightarrow & B \mid AW_a \mid W_c \\
 B & \rightarrow & BB_1 \mid BW_b \mid C \\
 B_1 & \rightarrow & AB_2 \\
 B_2 & \rightarrow & BB_3 \\
 B_3 & \rightarrow & AW_a \\
 C & \rightarrow & W_c \mid A \mid B \\
 W_a & \rightarrow & a \\
 W_b & \rightarrow & b \\
 W_c & \rightarrow & c
 \end{array}$$

- c) Beim Anwenden des Algorithmus CNF4 berechnen wir zunächst die Menge $V' = \{A, B, C\}$, welche alle Symbole enthalten, für die es eine Ableitung zum leeren Wort

gibt. Wir erhalten die folgende kontextfreie Grammatik nach Entfernen der ε -Regeln.

$$\begin{array}{lcl}
 S & \rightarrow & W_b A \mid BW_c \mid W_c \mid W_b \\
 A & \rightarrow & B \mid AW_a \mid W_c \mid W_a \\
 B & \rightarrow & BW_a \mid BW_b \mid C \mid W_a \mid W_b \\
 C & \rightarrow & W_c \mid A \mid B \\
 W_a & \rightarrow & a \\
 W_b & \rightarrow & b \\
 W_c & \rightarrow & c
 \end{array}$$

Es ist $U = \{(A, B), (A, C), (A, W_a), (A, W_b), (A, W_c), (B, C), (B, A), (B, W_a), (B, W_b), (B, W_c), (C, A), (C, B), (C, W_a), (C, W_b), (C, W_c), (S, W_b), (S, W_c)\}$. Jetzt entfernen wir die Einheits-Regeln, d.h. Regeln der Form $X \rightarrow Y$. Da C nun nicht mehr erreichbar ist, muss es entfernt werden. Wir erhalten folgende kontextfreie Grammatik.

$$\begin{array}{lcl}
 S & \rightarrow & W_b A \mid BW_c \mid c \mid b \\
 A & \rightarrow & AW_a \mid a \mid b \mid c \mid BW_a \mid BW_b \\
 B & \rightarrow & AW_a \mid a \mid b \mid c \mid BW_a \mid BW_b \\
 W_a & \rightarrow & a \\
 W_b & \rightarrow & b \\
 W_c & \rightarrow & c
 \end{array}$$

Aufgabe 5.3 [Sprachen und kontextfreie Grammatiken]

3 Punkte

Sei G die kontextfreie Grammatik mit den Produktionen

$$S \rightarrow aSbb \mid abb$$

und $L = \{a^n b^m \mid n, m \in \mathbb{N} \text{ und } m \geq 2n\}$ gegeben.

- Zeigen Sie, dass $L(G) \subseteq L$ gilt. Zeigen Sie dazu für ein beliebiges Wort $w \in L(G)$, dass w von der Form $a^n b^m$ mit $m, n \in \mathbb{N}$ und $m \geq 2n$ ist. Nutzen Sie dafür vollständige Induktion über die Länge k einer Ableitung von w . (2 Punkte)
- Gilt $L(G) \supseteq L$? (1 Punkt)

Lösung:

- Es ist zu zeigen, dass jedes Wort $w \in L(G)$ die Form $a^n b^m$ mit $m, n \in \mathbb{N}$ und $m \geq 2n$ hat. Ein Wort ist genau dann in $L(G)$, wenn es vom Startsymbol S abgeleitet werden kann. Wir nutzen vollständige Induktion über die Länge $k \geq 1$ der Ableitung von w , um zu zeigen, dass w die Form $a^n b^m$ mit $m \geq 2n$ hat.

Induktionsanfang: Wir haben nur eine Produktion, welche zur Länge $k = 1$ führen kann, dies ist $S \rightarrow abb$ und damit hat w die Form $a^1 b^2$.

Induktionsschritt: Unsere Induktionsvoraussetzung lautet, die Aussage ist wahr für $k - 1 \geq 1$, d.h. ein Wort, welches wir in $k - 1$ Schritten ableiten können ist in L . Wir behaupten, ein Wort, welches sich mit k Schritten ableiten lässt, ist in L . Eine Ableitung der Länge $k > 1$ beginnt mit Produktion $S \rightarrow aSbb$. Wir können eine Ableitung der

Länge k aufschreiben als $S \Rightarrow aSbb \Rightarrow^{(k-1)} aubb$. Da S die einzige Variable in der Satzform $aSbb$ ist, muss $S \Rightarrow^{(k-1)} u$ gelten und mit der Induktionsvoraussetzung folgern wir für das Teilwort u , dass dieses von der Form $a^n b^m$ mit $m \geq 2n$ ist. Damit ist w von der Form $a^{n'} b^{m'}$ mit $n' = n + 1$ und $m' = m + 2$ und folglich $m' \geq 2n'$. \square

- b) Nein, wir geben ein Gegenbeispiel an und zeigen, dass es ein Wort $w \in L$ gibt, welches nicht in $L(G)$ ist, und somit ist $L(G) \not\subseteq L$. Das Wort $w = a^1 b^3$ ist in $\{a^n b^m | n, m \in \mathbb{N} \text{ und } m \geq 2n\}$, da $3 \geq 2 \cdot 1$ gilt. Jedoch kann w unmöglich ausgehend vom Startsymbol von S abgeleitet werden. Da $abb \neq w$ müssen wir die Produktion $S \rightarrow aSbb$ anwenden. Jede weitere Anwendung einer der Produktionen führt zu mindestens zwei a -Symbolen in der Satzform, und damit, weil G kontextfrei ist, notwendigerweise auch in allen Wörtern, die aus der Satzform ableitbar sind. Folglich ist w zwar in L , jedoch nicht in $L(G)$. \square