

# Grundbegriffe der Theoretischen Informatik

Sommersemester 2018 - Thomas Schwentick

Teil B: Kontextfreie Sprachen

8: Normalformen und Korrektheitsbeweise

Version von: 15. Mai 2018 (12:02)


# Normalformen: Einleitung

## Erinnerung an die Logik-Vorlesung

- Für aussagenlogische Formeln gibt es verschiedene Normalformen:
  - konjunktive Normalform
  - disjunktive Normalform
  - Negationsnormalform
- Zu jeder aussagenlogischen Formel gibt es also eine äquivalente Formel mit einer gewissen syntaktischen Struktur
- Das ist für viele Zwecke nützlich:
  - Um den Resolutionskalkül anzuwenden, muss die Formel in KNF vorliegen
  - Um den Tableauekalkül anzuwenden, muss die Formel in NNF vorliegen

- Jetzt betrachten wir Normalformresultate für kontextfreie Grammatiken
- Sie besagen, dass es zu jeder kontextfreien Sprache eine Grammatik einer eingeschränkten Form gibt

- **Chomsky-Normalform:** Nur Regeln der Art
  - $X \rightarrow YZ$  und
  - $X \rightarrow \sigma$
- **Greibach-Normalform:** Nur Regeln der Art
  - $X \rightarrow \sigma X_1 \cdots X_k, k \geq 0$

 In beiden Fällen wird bei Bedarf zusätzlich eine Regel  $S \rightarrow \epsilon$  hinzu genommen

- Nutzen dieser Normalformen:
  - Die automatische Verarbeitung von Grammatiken wird erleichtert
    - weniger mögliche Fälle zu implementieren
  - Beweise werden übersichtlicher
    - weniger mögliche Fälle zu untersuchen

## ▷ 8.1 Chomsky-Normalform

8.2 Greibach-Normalform


8.3 Korrektheitsbeweise für kontextfreie Grammatiken

8.4 Anhang: Beweisdetails

# Chomsky-Normalform: Definition

## Definition (nützliche Variable)

- Eine Variable  $X$  einer Grammatik  $G = (V, \Sigma, S, P)$  heißt ⊕
  - **nützlich**, falls es eine Ableitung  $S \Rightarrow_G^* \alpha X \beta \Rightarrow_G^* w$  mit  $w \in \Sigma^*$  gibt

 Eine Variable ist also nützlich, wenn sie in mindestens einer Ableitung eines Wortes vorkommt

## Definition (Chomsky-Normalform, CNF)

- $G = (V, \Sigma, S, P)$  ist in **Chomsky-Normalform (CNF)** wenn
  - $G$  nur nützliche Variablen enthält und
  - alle Regeln von  $G$  die Form
    - \*  $X \rightarrow YZ$  oder
    - \*  $X \rightarrow \sigma$haben mit  $X, Y, Z \in V, \sigma \in \Sigma$
- Falls  $S$  in keiner rechten Regelseite vorkommt, ist zusätzlich die Regel  $S \rightarrow \epsilon$  erlaubt
- Wir werden jetzt beweisen, dass es zu jeder kontextfreien Grammatik eine äquivalente Grammatik in CNF gibt
- Der Beweis liefert auch einen Algorithmus für die Umwandlung in CNF

# Chomsky-Normalform: Ausblick

- Grammatiken werden durch die Umwandlung in CNF meist größer, aber homogener, wie sich an der Beispiel-Grammatik zeigen wird

## Beispiel-Grammatik: $G_0$

$$\begin{aligned} S &\rightarrow bDD \mid Ca \mid bc \\ A &\rightarrow B \mid aCC \mid baD \\ B &\rightarrow cBD \mid \epsilon \mid AC \\ C &\rightarrow bD \mid aBA \\ D &\rightarrow CD \mid a \mid EF \\ E &\rightarrow Eb \\ F &\rightarrow a \end{aligned}$$

## Beispiel-Grammatik in CNF

$$\begin{aligned} S &\rightarrow W_b S_1 \mid C W_a \mid W_b W_c \\ S_1 &\rightarrow DD \\ A &\rightarrow W_a A_1 \mid W_b A_2 \mid W_c B_1 \mid AC \mid \\ &\quad W_b D \mid W_a C_1 \mid a \\ A_1 &\rightarrow CC \\ A_2 &\rightarrow W_a D \\ B &\rightarrow W_c B_1 \mid AC \mid W_b D \mid W_a C_1 \mid a \\ B_1 &\rightarrow BD \mid CD \mid a \\ C &\rightarrow W_b D \mid W_a C_1 \mid a \\ C_1 &\rightarrow BA \mid W_a A_1 \mid W_b A_2 \mid W_c B_1 \mid \\ &\quad AC \mid W_b D \mid W_a C_1 \mid a \\ D &\rightarrow CD \mid a \\ W_a &\rightarrow a \\ W_b &\rightarrow b \\ W_c &\rightarrow c \end{aligned}$$

# Chomsky-Normalform: Satz

## Satz 8.1 [Chomsky 59]

- Für jede kontextfreie Sprache  $L$  gibt es eine Grammatik  $G$  in Chomsky-Normalform mit  $L(G) = L$

## Beweisskizze

- Sei  $G_0 = (V, \Sigma, S, P)$  eine Grammatik für  $L$
- Wir entfernen in  $G_0$  nach und nach die Merkmale, die der CNF im Weg stehen und konstruieren dafür Grammatiken mit folgenden Eigenschaften:

( $G_1$ ) nur nützliche Variablen

( $G_2$ ) rechte Seiten enthalten genau ein Terminalsymbol oder nur Variablen

( $G_3$ ) ohne Regeln  $X \rightarrow \beta$  mit  $|\beta| > 2$

( $G_4$ ) ohne  $\epsilon$ -Regeln

( $G_5$ ) ohne Regeln der Art  $X \rightarrow Y$

- Es gilt dann  $L(G_5) = L - \{\epsilon\}$ , deshalb muss  $G_5$  evtl. um  $S \rightarrow \epsilon$  ergänzt werden

# CNF: (1) Entfernen von nutzlosen Variablen (1/4)

## Definition (erreichbare, erzeugende Variable)

- Eine Variable  $X$  einer Grammatik  $G = (V, \Sigma, S, P)$  heißt
  - **erreichbar**, falls es eine Ableitung  $S \Rightarrow_G^* \alpha X \beta$  gibt
  - **erzeugend**, falls es eine Ableitung  $X \Rightarrow_G^* w$  mit  $w \in \Sigma^*$  gibt



- Klar: nützlich  $\Rightarrow$  erreichbar und erzeugend


## Beispiel

- In der Grammatik
$$\begin{array}{l} S \rightarrow AB \mid a \\ A \rightarrow b \\ C \rightarrow ab \end{array}$$
ist
  - $S$  nützlich
  - $C$  erzeugend, aber nicht erreichbar
  - $B$  erreichbar, aber nicht erzeugend
  - $A$  erreichbar und erzeugend, aber nicht nützlich

- Wie die Variable  $A$  im Beispiel zeigt, ist eine erreichbare und erzeugende Variable nicht immer nützlich
- Es genügt aber, zuerst die nicht erzeugenden und dann die (dann) nicht erreichbaren Variablen zu entfernen

## Algorithmus CNF1


- 1:  $G'_1 := G_0$  ohne die nicht erzeugenden Variablen
- 2:  $G_1 := G'_1$  ohne die nicht erreichbaren Variablen

 Dabei werden jeweils außer den Variablen auch alle Regeln entfernt, in denen sie (links oder rechts) vorkommen

## CNF: (1) Entfernen von nutzlosen Variablen (2/4)

- Berechnung der Menge  $V_e$  der **erzeugenden Variablen**:

- Initialisiere  $V_e$  durch die Menge aller Variablen  $X$ , für die es eine Regel gibt, deren rechte Seite nur aus Terminalsymbolen besteht

 Also eine Regel  $X \rightarrow \alpha$  mit  $\alpha \in \Sigma^*$

- Solange möglich, füge Variablen  $X$  zu  $V_e$  hinzu, wenn sie eine Regel haben, die auf der rechten Seite nur Terminalsymbole und Variablen aus  $V_e$  enthält

- Variablen, die am Ende nicht in  $V_e$  sind, sind nicht erzeugend

Beispiel-Grammatik:  $G_0$

$$\begin{aligned} S &\rightarrow bDD \mid Ca \mid bc \\ A &\rightarrow B \mid aCC \mid baD \\ B &\rightarrow cBD \mid \epsilon \mid AC \\ C &\rightarrow bD \mid aBA \\ D &\rightarrow CD \mid a \mid EF \\ E &\rightarrow Eb \\ F &\rightarrow a \end{aligned}$$

- $E$  ist nicht erzeugend und wird daher nicht in  $G'_1$  aufgenommen

$G'_1$

$$\begin{aligned} S &\rightarrow bDD \mid Ca \mid bc \\ A &\rightarrow B \mid aCC \mid baD \\ B &\rightarrow cBD \mid \epsilon \mid AC \\ C &\rightarrow bD \mid aBA \\ D &\rightarrow CD \mid a \\ F &\rightarrow a \end{aligned}$$



## CNF: (1) Entfernen von nutzlosen Variablen (3/4)

- Berechnung der **nicht erreichbaren Variablen**:
- Konstruiere einen Graphen  $H(G'_1)$  zu  $G'_1$ :
  - Knotenmenge: Variablen von  $G'_1$
  - Kante von  $X$  nach  $Y$ , wenn  $Y$  auf der rechten Seite einer Regel zu  $X$  vorkommt
- Berechne alle in diesem Graphen von  $S$  aus erreichbaren Knoten
- Die übrigen Knoten sind nicht erreichbar

$G'_1$

$$\begin{aligned} S &\rightarrow bDD \mid Ca \mid bc \\ A &\rightarrow B \mid aCC \mid baD \\ B &\rightarrow cBD \mid \epsilon \mid AC \\ C &\rightarrow bD \mid aBA \\ D &\rightarrow CD \mid a \\ F &\rightarrow a \end{aligned}$$

- $F$  ist in  $G'_1$  nicht erreichbar

$G_1$

$$\begin{aligned} S &\rightarrow bDD \mid Ca \mid bc \\ A &\rightarrow B \mid aCC \mid baD \\ B &\rightarrow cBD \mid \epsilon \mid AC \\ C &\rightarrow bD \mid aBA \\ D &\rightarrow CD \mid a \end{aligned}$$

# CNF: (1) Entfernen von nutzlosen Variablen (4/4)

## Lemma 8.2

- Sei  $G_1$  durch Algorithmus CNF1 berechnet
- Dann gelten:
  - (a)  $L(G_1) = L(G_0)$
  - (b)  $G_1$  enthält nur nützliche Variablen

## Beweisidee

- (a) –  $L(G_1) \subseteq L(G_0)$ :
  - \* weil alle Regeln aus  $G_1$  auch in  $G_0$  vorkommen
- $L(G_0) \subseteq L(G_1)$ :
  - \* weil alle in einer Ableitung  $S \Rightarrow_{G_0}^* w$  vorkommenden Variablen und Regeln bei der Umwandlung in  $G_1$  erhalten bleiben
- (b) – Sei  $X$  eine Variable von  $G_1$ 
  - ➡  $X$  ist erreichbar in  $G'_1$
  - ➡  $S \Rightarrow_{G'_1}^* \alpha X \beta$  für gewisse  $\alpha, \beta$ 
    - Wegen Schritt (1) des Algorithmus sind  $X$  und alle Symbole aus  $\alpha, \beta$  erzeugend in  $G'_1$   
(und damit auch in  $G_1$ )
  - ➡  $X$  ist nützlich

## CNF: (2) Variablen und Terminalsymbole trennen

### Algorithmus CNF2

- 1: **for** jedes Terminalsymbol  $\sigma \in \Sigma$  **do**
- 2:   Füge eine neue Variable  $W_\sigma$  hinzu
- 3:   Ersetze in allen rechten Regelseiten  $\sigma$  durch  $W_\sigma$
- 4:   Füge eine neue Regel  $W_\sigma \rightarrow \sigma$  hinzu

### Lemma 8.3

- Sei  $G_2$  durch Algorithmus CNF2 aus  $G_1$  berechnet
- Dann gelten:
  - (a)  $L(G_2) = L(G_1)$
  - (b) Jede rechte Regelseite von  $G_2$  ist von einem der folgenden drei Typen:
    - ein Terminalsymbol
    - $\epsilon$
    - ein oder mehrere Variablen

## CNF: (2) Variablen und Terminalsymbole trennen: Beispiel

$G_1$

$$\begin{aligned} S &\rightarrow bDD \mid Ca \mid bc \\ A &\rightarrow B \mid aCC \mid baD \\ B &\rightarrow cBD \mid \epsilon \mid AC \\ C &\rightarrow bD \mid aBA \\ D &\rightarrow CD \mid a \end{aligned}$$

$G_2$

$$\begin{aligned} S &\rightarrow W_bDD \mid CW_a \mid W_bW_c \\ A &\rightarrow B \mid W_aCC \mid W_bW_aD \\ B &\rightarrow W_cBD \mid \epsilon \mid AC \\ C &\rightarrow W_bD \mid W_aBA \\ D &\rightarrow CD \mid W_a \\ W_a &\rightarrow a \\ W_b &\rightarrow b \\ W_c &\rightarrow c \end{aligned}$$

## CNF: (3) Rechte Seiten verkürzen

### Algorithmus CNF3

1: Entferne jede Regel der Art

$$X \rightarrow Y_1 \cdots Y_k, \text{ mit } k > 2$$

2: Füge dafür folgende Regeln hinzu:

$$\begin{array}{lcl} X & \rightarrow & Y_1 Z_1 \\ Z_1 & \rightarrow & Y_2 Z_2 \\ \vdots & \rightarrow & \vdots \\ Z_{k-2} & \rightarrow & Y_{k-1} Y_k \end{array}$$

- Dabei sind die  $Z_i$  neue (und für jede ersetzte Regel andere) Variablen, für alle  $i \in \{1, \dots, k-2\}$

### Lemma 8.4

- Sei  $G_3$  durch Algorithmus CNF3 aus  $G_2$  berechnet
- Dann gelten:
  - (a)  $L(G_3) = L(G_2)$
  - (b) Jede rechte Regelseite von  $G_3$  ist von einem der folgenden Typen:
    - ein Terminalsymbol
    - $\epsilon$
    - eine Variable
    - zwei Variablen

## CNF: (3) Rechte Seiten verkürzen: Beispiel

$G_2$

$$S \rightarrow W_b D D \mid C W_a \mid W_b W_c$$

$$A \rightarrow B \mid W_a C C \mid W_b W_a D$$

$$B \rightarrow W_c B D \mid \epsilon \mid A C$$

$$C \rightarrow W_b D \mid W_a B A$$

$$D \rightarrow C D \mid W_a$$

$$W_a \rightarrow a$$

$$W_b \rightarrow b$$

$$W_c \rightarrow c$$

$G_3$

$$S \rightarrow W_b S_1 \mid C W_a \mid W_b W_c$$

$$S_1 \rightarrow D D$$

$$A \rightarrow B \mid W_a A_1 \mid W_b A_2$$

$$A_1 \rightarrow C C$$

$$A_2 \rightarrow W_a D$$

$$B \rightarrow W_c B_1 \mid \epsilon \mid A C$$

$$B_1 \rightarrow B D$$

$$C \rightarrow W_b D \mid W_a C_1$$

$$C_1 \rightarrow B A$$

$$D \rightarrow C D \mid W_a$$

$$W_a \rightarrow a$$

$$W_b \rightarrow b$$

$$W_c \rightarrow c$$

## CNF: (4) $\epsilon$ -Regeln entfernen (1/3)

### Beispiel

- Was ist zu beachten, wenn eine Grammatik (unter anderem) die Regeln

$$A \rightarrow BC$$

$$B \rightarrow EF$$

$$C \rightarrow DE$$

$$D \rightarrow E$$

$$E \rightarrow \epsilon$$

enthält und wir die  $\epsilon$ -Regel  $E \rightarrow \epsilon$  entfernen wollen?

- Um weiterhin den Effekt der (Teil-)Ableitung  $B \Rightarrow EF \Rightarrow F$  zu ermöglichen, sollte die Regel  $B \rightarrow F$  hinzugefügt werden
- Das Entfernen von  $E \rightarrow \epsilon$  bewirkt aber auch, dass  $\epsilon$  nicht mehr von  $D$  und  $C$  abgeleitet werden kann
- Deshalb müssen auch für Vorkommen dieser Variablen auf rechten Regelseiten Ergänzungen vorgenommen werden:  
 $\rightarrow$  z.B. neue Regel:  $A \rightarrow B$

- Der folgende Algorithmus CNF4 berechnet deshalb zunächst die Menge  $V'$  aller Variablen, von denen der Leerstring abgeleitet werden kann
- Für jedes Vorkommen dieser Variablen in rechten Regelseiten fügt er dann neue Regeln ein
- Alle  $\epsilon$ -Regeln werden dann entfernt
- Es ist klar, dass der Leerstring danach nicht mehr erzeugt werden kann

## CNF: (4) $\epsilon$ -Regeln entfernen (2/3)

### Algorithmus CNF4

- 1:  $V' := \{X \mid X \Rightarrow^* \epsilon\}$
- 2: **for**  $X \rightarrow YZ$  in  $P$  **do**
- 3:   **if**  $Z \in V'$  **then**
- 4:     Füge Regel  $X \rightarrow Y$  hinzu
- 5:   **if**  $Y \in V'$  **then**
- 6:     Füge Regel  $X \rightarrow Z$  hinzu
- 7: Entferne alle Regeln der Art  $X \rightarrow \epsilon$
- 8: Entferne nutzlos gewordene Variablen mit CNF1

### Lemma 8.5

- Sei  $G_4$  durch Algorithmus CNF4 aus  $G_3$  berechnet
- Dann gelten:
  - (a)  $L(G_4) = L(G_3) - \{\epsilon\}$
  - (b) Jede rechte Regelseite von  $G_4$  ist von einem der folgenden 3 Typen:
    - ein Terminalsymbol
    - eine Variable
    - zwei Variablen



## CNF: (4) $\epsilon$ -Regeln entfernen: Beispiel

$G_3$

$$\begin{aligned} S &\rightarrow W_b S_1 \mid C W_a \mid W_b W_c \\ S_1 &\rightarrow D D \\ A &\rightarrow B \mid W_a A_1 \mid W_b A_2 \\ A_1 &\rightarrow C C \\ A_2 &\rightarrow W_a D \\ B &\rightarrow W_c B_1 \mid \epsilon \mid A C \\ B_1 &\rightarrow B D \\ C &\rightarrow W_b D \mid W_a C_1 \\ C_1 &\rightarrow B A \\ D &\rightarrow C D \mid W_a \\ W_a &\rightarrow a \\ W_b &\rightarrow b \\ W_c &\rightarrow c \end{aligned}$$

- $V' = \{A, B, C_1\}$

$G_4$

$$\begin{aligned} S &\rightarrow W_b S_1 \mid C W_a \mid W_b W_c \\ S_1 &\rightarrow D D \\ A &\rightarrow B \mid W_a A_1 \mid W_b A_2 \\ A_1 &\rightarrow C C \\ A_2 &\rightarrow W_a D \\ B &\rightarrow W_c B_1 \mid A C \mid C \\ B_1 &\rightarrow B D \mid D \\ C &\rightarrow W_b D \mid W_a C_1 \mid W_a \\ C_1 &\rightarrow B A \mid A \mid B \\ D &\rightarrow C D \mid W_a \\ W_a &\rightarrow a \\ W_b &\rightarrow b \\ W_c &\rightarrow c \end{aligned}$$

## CNF: (4) $\epsilon$ -Regeln entfernen (3/3)

### Algorithmus CNF4

- 1:  $V' := \{X \mid X \Rightarrow^* \epsilon\}$
- 2: **for**  $X \rightarrow YZ$  in  $P$  **do**
- 3:   **if**  $Z \in V'$  **then**
- 4:     Füge Regel  $X \rightarrow Y$  hinzu
- 5:   **if**  $Y \in V'$  **then**
- 6:     Füge Regel  $X \rightarrow Z$  hinzu
- 7: Entferne alle Regeln der Art  $X \rightarrow \epsilon$
- 8: Entferne nutzlos gewordene Variablen (CNF1)

### Beweisidee für Lemma 8.5

- Da der Algorithmus sowohl Regeln hinzufügt als auch Regeln entfernt, ist der Nachweis, dass die neue Grammatik äquivalent ist (bis auf  $\epsilon$ ), etwas kompliziert
- Es wird bewiesen, dass für jede Variable  $X$  von  $G_3$  und jeden String  $w \in \Sigma^* - \{\epsilon\}$  äquivalent sind:
  - (1)  $X \Rightarrow_{G_4}^* w$
  - (2)  $X \Rightarrow_{G_3}^* w$
- Für „(1)  $\Rightarrow$  (2)“ lässt sich für jede neue Regel  $X \rightarrow Y$  in  $G_4$  zeigen:
$$X \Rightarrow_{G_3}^* Y$$
- Für „(2)  $\Rightarrow$  (1)“ lässt sich durch Induktion nach  $n$  zeigen:
$$X \Rightarrow_{G_3}^n w \Rightarrow X \Rightarrow_{G_4}^* w$$
- Weitere Details im Anhang

## CNF: (5) Einzel-Variablen der rechten Seite entfernen (1/2)

- Jetzt müssen nur noch die **Einheits-Regeln** entfernt werden, also Regeln der Form  $X \rightarrow Y$

### Beispiel

- Was ist beim Entfernen der Einheits-Regeln aus einer Grammatik, die folgende Regeln enthält, zu beachten?

$$A \rightarrow BC$$

$$B \rightarrow D$$

$$C \rightarrow DF$$

$$D \rightarrow E$$

$$E \rightarrow e$$

- Um den Effekt der Ableitung  $C \Rightarrow DF \Rightarrow EF \Rightarrow eF$  zu erhalten, nehmen wir die Regel  $D \rightarrow e$  auf:

$$C \Rightarrow DF \Rightarrow eF$$

- Um den Effekt der Ableitung

$$A \Rightarrow BC \Rightarrow DC \Rightarrow EC \Rightarrow eC$$

zu erhalten, nehmen wir auch noch  $B \rightarrow e$  auf:

$$A \Rightarrow BC \Rightarrow eC$$

- Der folgende Algorithmus CNF5 berechnet zunächst alle Variablenpaare  $X \neq Y$ , für die  $X \Rightarrow^* Y$  gilt

- Dann fügt er für jedes solche Paar zu jeder binären Regel  $Y \rightarrow \alpha$  eine neue Regel  $X \rightarrow \alpha$  hinzu

## CNF: (5) Einzel-Variablen der rechten Seite entfernen (2/2)


### Algorithmus CNF5

- 1:  $U := \{(X, Y) \mid X \Rightarrow_{G_4}^* Y, X \neq Y\}$
- 2: **for**  $(X, Y)$  in  $U$  und jede Nicht-Einheitsregel  $Y \rightarrow \alpha$  **do**
- 3:   Füge neue Regel  $X \rightarrow \alpha$  ein
- 4: Entferne alle Einheitsregeln
- 5: Entferne alle nicht erreichbaren Variablen (und ihre Regeln)

### Lemma 8.6

- Sei  $G_5$  durch Algorithmus CNF5 aus  $G_4$  berechnet
- Dann gelten:
  - (a)  $L(G_5) = L(G_4)$
  - (b)  $G_5$  ist in Chomsky-Normalform

### Beweisidee

- „ $L(G_5) \subseteq L(G_4)$ “:
  - Für jede neue Regel  $X \rightarrow \alpha$  von  $G_5$  gibt es in  $G_4$  eine Variable  $Y$ , so dass gilt:
    - \*  $X \Rightarrow_{G_4}^* Y$
    - \*  $Y \rightarrow \alpha$  ist Regel in  $G_4$
  - Also gibt es für jede neue Regel  $X \rightarrow \alpha$  von  $G_5$  in  $G_4$  eine Ableitung  $X \Rightarrow_{G_4}^* \alpha$
- „ $L(G_4) \subseteq L(G_5)$ “:
  - Jede Folge  $X \Rightarrow_{G_4} \dots \Rightarrow_{G_4} Y \Rightarrow_{G_4} \alpha$  kann in  $G_5$  durch Anwendung von  $X \rightarrow \alpha$  ersetzt werden
    -  Dabei ist  $\alpha$  keine Variable!
- Weitere Details im Anhang

## CNF: (5) Einzel-Variablen entfernen (Beispiel)

$G_4$

$$\begin{aligned}
 S &\rightarrow W_b S_1 \mid C W_a \mid W_b W_c \\
 S_1 &\rightarrow D D \\
 A &\rightarrow B \mid W_a A_1 \mid W_b A_2 \\
 A_1 &\rightarrow C C \\
 A_2 &\rightarrow W_a D \\
 B &\rightarrow W_c B_1 \mid A C \mid C \\
 B_1 &\rightarrow B D \mid D \\
 C &\rightarrow W_b D \mid W_a C_1 \mid W_a \\
 C_1 &\rightarrow B A \mid A \mid B \\
 D &\rightarrow C D \mid W_a \\
 W_a &\rightarrow a \\
 W_b &\rightarrow b \\
 W_c &\rightarrow c
 \end{aligned}$$

$$U = \{(C_1, A), (A, B), (B, C), \\
 (C, W_a), (B_1, D), (D, W_a), \\
 (C_1, B), (C_1, C), (C_1, W_a), \\
 (A, C), (A, W_a), (B, W_a), (B_1, W_a)\}$$

$G_5$

$$\begin{aligned}
 S &\rightarrow W_b S_1 \mid C W_a \mid W_b W_c \\
 S_1 &\rightarrow D D \\
 A &\rightarrow W_a A_1 \mid W_b A_2 \mid W_c B_1 \mid A C \mid \\
 &\quad W_b D \mid W_a C_1 \mid a \\
 A_1 &\rightarrow C C \\
 A_2 &\rightarrow W_a D \\
 B &\rightarrow W_c B_1 \mid A C \mid W_b D \mid W_a C_1 \mid a \\
 B_1 &\rightarrow B D \mid C D \mid a \\
 C &\rightarrow W_b D \mid W_a C_1 \mid a \\
 C_1 &\rightarrow B A \mid W_a A_1 \mid W_b A_2 \mid W_c B_1 \mid \\
 &\quad A C \mid W_b D \mid W_a C_1 \mid a \\
 D &\rightarrow C D \mid a \\
 W_a &\rightarrow a \\
 W_b &\rightarrow b \\
 W_c &\rightarrow c
 \end{aligned}$$

# Chomsky-Normalform: Abschluss der Beweisskizze

- Falls die Sprache  $L$  den String  $\epsilon$  enthält, ergänzen wir noch einen weiteren Schritt

## Algorithmus CNF6

- 1: **if**  $\epsilon \in L$  und  $S$  kommt in keiner rechten Seite einer Regel vor **then**
- 2:   Füge neue Regel  $S \rightarrow \epsilon$  ein
- 3: **else**
- 4:   Füge ein neues Startsymbol  $S'$  und die Regel  $S' \rightarrow \epsilon$  hinzu
- 5:   Füge für jede Regel  $S \rightarrow \alpha$  die Regel  $S' \rightarrow \alpha$  hinzu

## Satz 8.1 [Chomsky 59]

- Für jede kontextfreie Sprache  $L$  gibt es eine Grammatik  $G$  in Chomsky-Normalform mit  $L(G) = L$

## Beweisskizze

- Sei  $G_0 = (V, \Sigma, S, P)$  eine Grammatik für  $L$
- Für die wie beschrieben konstruierten Grammatiken  $G_1, \dots, G_5$  gilt:

$$\begin{aligned} L(G_5) &= L(G_4) && \text{Lemma 8.6} \\ &= L(G_3) - \{\epsilon\} && \text{Lemma 8.5} \\ &= L(G_2) - \{\epsilon\} && \text{Lemma 8.4} \\ &= L(G_1) - \{\epsilon\} && \text{Lemma 8.3} \\ &= L(G_0) - \{\epsilon\} && \text{Lemma 8.2} \end{aligned}$$

- Falls  $\epsilon \notin L(G_0)$ , gilt also  $L(G_5) = L(G_0)$
- Falls  $\epsilon \in L(G_0)$ , gilt für die in CNF6 konstruierte Grammatik:  $L(G_6) = L(G_0)$

## CNF: Größe

- Wie groß wird die durch den Algorithmus insgesamt konstruierte CNF-Grammatik im Vergleich zur Ausgangsgrammatik?
- Sei  $m = |\Sigma|$  und, für jedes  $i$  jeweils
  - $n_i$  die Anzahl der Variablen von  $G_i$ ,
  - $k_i$  die Anzahl der Produktionen von  $G_i$
  - $l_i$  die maximale Länge einer rechten Seite von  $G_i$
- Dann gilt für die einzelnen Teilschritte:
  1. Alle Parameter können allenfalls kleiner werden
  2.  $n_2 = n_1 + m, k_2 = k_1 + m$
  3.  $n_3 = \mathcal{O}(k_2 l_2), k_3 = \mathcal{O}(l_2 k_2), l_3 = 2$
  4.  $k_4 \leq 3k_3$
  5.  $k_5 = \mathcal{O}(k_4 n_4)$
- Insgesamt also:
  - $k_5 = \mathcal{O}(l_0^2 (m + k_0)^2) = \mathcal{O}(|G_0|^4)$
  - $n_5 = \mathcal{O}(l_0 (k_0 + m))$

# Inhalt

8.1 Chomsky-Normalform

▷ **8.2 Greibach-Normalform**

8.3 Korrektheitsbeweise für kontextfreie Grammatiken

8.4 Anhang: Beweisdetails



# Greibach-Normalform (1/2)

## Definition (Greibach-Normalform, GNF)

- Eine kontextfreie Grammatik  $G = (V, \Sigma, S, P)$  ist in **Greibach-Normalform** (GNF) wenn
  - $V$  nur nützliche Variablen enthält und
  - alle Regeln von  $G$  von der Form
    - \*  $X \rightarrow \sigma Y_1 \cdots Y_k$   
mit  $X, Y_1, \dots, Y_k \in V, \sigma \in \Sigma$   
sind
- Falls  $S$  in keiner rechten Regelseite vorkommt, ist zusätzlich die Regel  $S \rightarrow \epsilon$  erlaubt

## Satz 8.7 [Greibach 65]

- Ist  $L$  kontextfrei, so gibt es eine Grammatik  $G$  in Greibach-Normalform, so dass  $L(G) = L$

## Kurz-Bio: Sheila Greibach

- Geboren: 1939
- Studium am Radcliffe College, Cambridge, Massachusetts
- Professorin an der University of California, Los Angeles
- Arbeitsgebiete: Formale Sprachen, Compilerbau, Theoretische Informatik

(Quellen: Wikipedia)

## Greibach-Normalform (2/2)

- Es ist in der Greibach-Normalform sogar möglich, die Anzahl der Variablen in rechten Regelseiten auf maximal zwei zu beschränken
- Es gibt dann also nur Regeln der Art:
  - $X \rightarrow \sigma$
  - $X \rightarrow \sigma Y$
  - $X \rightarrow \sigma Y Z$

### Beispiel

- Die Grammatik  $G'_{a=b}$ :
$$\begin{aligned} S &\rightarrow aB \mid bA \mid \epsilon \\ S' &\rightarrow aB \mid bA \\ A &\rightarrow aS' \mid bAA \mid a \\ B &\rightarrow bS' \mid aBB \mid b \end{aligned}$$

ist in Greibach-Normalform

### Bemerkungen

- Ist  $G$  in GNF, so haben Strings der Länge  $n$  Ableitungen der Länge  $n$
- Der Beweis von Satz 8.7 ist (noch) aufwändiger als der Beweis von Satz 8.1  
→ Buch von Ingo Wegener  
(siehe auch: [Blum, Koch 99])

# Inhalt

8.1 Chomsky-Normalform


8.2 Greibach-Normalform

▷ **8.3 Korrektheitsbeweise für kontextfreie Grammatiken**

8.4 Anhang: Beweisdetails

# Korrektheitsbeweise für Grammatiken: allgemein

- Sei  $G$  eine Grammatik und  $L$  eine Sprache
- Wie lässt sich beweisen, dass  $L(G) = L$  gilt?
- Wie üblich: Zeige  $L(G) \subseteq L$  und  $L \subseteq L(G)$
- $L(G) \subseteq L$  bedeutet, dass die Grammatik *nur* Strings aus  $L$  erzeugt ☞ Korrektheit
  - Der Korrektheitsbeweis ist meist durch Induktion nach der Ableitungslänge möglich
- $L \subseteq L(G)$  bedeutet, dass die Grammatik *alle* Strings aus  $L$  erzeugt ☞ Vollständigkeit
  - Meistens durch Induktion nach der Wortlänge
  - Der Induktionsschritt verwendet meist eine geeignete Fallunterscheidung
  - Hier ist oft eine weitere, nicht-induktive Definition von  $L$  nötig
- Hat eine Grammatik mehrere Variablen, so wird meist für jede Variable  $X$  gezeigt, was die Sprache  $L(X)$  der von  $X$  aus ableitbaren Strings ist

-  **Faustregel:**
- Zum Beweis der Korrektheit wird im Ableitungsbaum „von oben nach unten“ argumentiert
  - Zum Beweis der Vollständigkeit von unten nach oben
- 
- Wir betrachten im Folgenden drei Korrektheitsbeweise:
    - für eine sehr einfache Grammatik: Palindrome
    - für eine etwas trickreichere Grammatik:  $G_{a=b}$
    - für eine ziemlich trickreiche Grammatik:  $G_{\text{diff}}$

# Korrektheitsbeweise: Palindrome (1/2)

- Zur Erinnerung:

$$L_{\text{pali}} = \{w \in \{a, b\}^* \mid w^R = w\}$$

- Mit  $G_{\text{pali}}$  bezeichnen wir die Grammatik

$$P \rightarrow \epsilon \mid a \mid b \mid aPa \mid bPb$$

- Nicht-induktive Definition von Palindromen:

- Ein String  $w$  ist genau dann ein Palindrom, wenn für alle  $i \in \{1, \dots, |w|\}$  gilt:

$$w[i] = w[|w| - i + 1]$$

## Proposition 8.8

- $L(G_{\text{pali}}) = L_{\text{pali}}$

## Beweisskizze

- Korrektheit „ $L(G_{\text{pali}}) \subseteq L_{\text{pali}}$ “:

- Sei  $w \in L(G_{\text{pali}})$

$$\Rightarrow P \Rightarrow^k w \text{ für ein } k \geq 1$$

- Wir zeigen  $w \in L$  durch Induktion nach der Ableitungslänge  $k$

- $k = 1$ :

- \*  $\epsilon, a, b$  sind Palindrome ✓

- $k > 1$ :

- \* Fallunterscheidung nach dem ersten Ableitungsschritt

- \* 1. Fall:  $P \Rightarrow aPa \Rightarrow^{k-1} ava = w$ ,  
für ein  $v \in \{a, b\}^*$

$$\Rightarrow P \Rightarrow^{k-1} v$$

$$\Rightarrow v^R = v$$

☞ Induktion

$$\Rightarrow w^R = av^Ra = ava = w$$

- \* 2. Fall:  $P \Rightarrow bPb \Rightarrow^{k-1} bvb = w$ ,  
für ein  $v \in \{a, b\}^*$

→ analog

# Korrektheitsbeweise: Palindrome (2/2)

## Beweisskizze (Forts.)

- **Vollständigkeit** „ $L_{\text{pali}} \subseteq L(G_{\text{pali}})$ “:

- Sei  $w \in L_{\text{pali}}$  und  $n \stackrel{\text{def}}{=} |w|$
- Wir zeigen  $w \in L(G_{\text{pali}})$  durch Induktion nach  $n$

- $n \in \{0, 1\}$ :

- ➡  $w \in \{\epsilon, a, b\}$  ist ableitbar ✓

- $n \geq 2$ :

- \* 1. Fall:  $w[1] = a$

- ➡  $w[n] = a$

- ➡  $w = ava$  für einen String  $v$  der Länge  $n - 2$

- Da  $w^R = w$  gilt auch  $v^R = v$ , denn, für alle  $i \leq n - 2$ :

- $$v[i] = w[i + 1]$$

- ☞ Def von  $v$

- $$= w[n - (i + 1) + 1]$$

- ☞  $w$  Palindrom

- $$= v[n - (i + 1)]$$

- ☞ Def von  $v$

- $$= v[(n - 2) - i + 1]$$

- Induktion:  $P \Rightarrow^* v$

- ➡  $P \Rightarrow aPa \Rightarrow^* ava = w$

- \* 2. Fall:  $w[1] = b$  analog

# Korrektheitsbeweise: $L_{a=b}$ (1/2)

- Zur Erinnerung:

$$- L_{a=b} = \{w \in \{a, b\}^* \mid \#_a(w) = \#_b(w)\}$$

- $G_{a=b}$  ist  
 $S \rightarrow aSbS \mid bSaS \mid \epsilon$

## Proposition 8.9

$$\bullet L(G_{a=b}) = L_{a=b}$$

## Beweisskizze: Korrektheit

- Zu zeigen:  $L(G_{a=b}) \subseteq L_{a=b}$
- Sei  $w \in L(G_{a=b})$
- Induktion nach der Ableitungslänge  $k$ :

$$\bullet k = 1: S \Rightarrow \epsilon \checkmark$$

- $k > 1$ : Fallunterscheidung nach dem ersten Ableitungsschritt

$$- 1. \text{ Fall: } S \Rightarrow aSbS \Rightarrow^{k-1} aubv = w$$

$$\begin{aligned} * \text{ Induktion: } \#_a(u) &= \#_b(u) \text{ und} \\ \#_a(v) &= \#_b(v) \end{aligned}$$



$$\begin{aligned} \#_a(w) &= \#_a(u) + \#_a(v) + 1 \\ &= \#_b(u) + \#_b(v) + 1 \\ &= \#_b(w) \end{aligned}$$

$$- 2. \text{ Fall: } S \Rightarrow bSaS \Rightarrow^* buav = w \text{ analog}$$

## Korrektheitsbeweise: $L_{a=b}$ (2/2)

- Sei für jeden String  $w \in \{a, b\}^*$ :  

$$\underline{d(w)} \stackrel{\text{def}}{=} \#_b(w) - \#_a(w)$$
- Also:  $L_{a=b} = \{w \in \{a, b\}^* \mid d(w) = 0\}$

### Beweisskizze: Vollständigkeit

- Zu zeigen:  $L_{a=b} \subseteq L(G_{a=b})$
- Sei  $w \in L_{a=b}$
- Induktion nach  $n \stackrel{\text{def}}{=} |w|$
- $n = 0$ :  $S \Rightarrow \epsilon \checkmark$


### Beweisskizze (Forts.)

- $n > 0$ :
  - 1. Fall:  $w = au$  für ein  $u \in \{a, b\}^*$  mit  $|u| = n - 1$  ⊕
    - Da  $d(w) = 0$  gilt  $d(u) = 1$
    - Sei  $i \geq 1$  die kleinste Zahl mit  $d(u[1, i]) = 1$
    - ➡  $d(u[1, i - 1]) = 0$  und  $u[i] = b$ 
      - Außerdem:  $d(u[i + 1, n - 1]) = d(w) - d(u[1, i]) - 1 = 0$
      - Induktion:  $S \Rightarrow^* u[1, i - 1]$  und  $S \Rightarrow^* u[i + 1, n - 1]$
      - ➡  $S \Rightarrow aSbS \Rightarrow^* au[1, i - 1]bu[i + 1, n - 1] = au = w$
  - Der Fall  $w = bv$  ist analog



## Korrektheitsbeweise: $L_{\text{diff}}$ (1/3)

- Für einen String  $w$  gerader Länge bezeichne  $1^{\text{st}}(w)$  seine erste Hälfte und  $2^{\text{nd}}(w)$  seine zweite Hälfte


 Für Strings ungerader Länge seien beide Funktionen undefiniert

- Sei  $L_{\text{diff}} \stackrel{\text{def}}{=} \{w \in \{a, b\}^* \mid 1^{\text{st}}(w) \neq 2^{\text{nd}}(w)\}$

- Idee für die Konstruktion einer Grammatik:

– Sorge dafür, dass  $a$  in  $1^{\text{st}}(w)$  an derselben Stelle steht wie  $b$  in  $2^{\text{nd}}(w)$

\* Erlaube ansonsten beliebige Zeichen

 Oder umgekehrt mit  $b$  in  $1^{\text{st}}(w)$  und  $a$  in  $2^{\text{nd}}(w)$

- Setze dazu  $w = w_1 w_2$  aus Teilstrings  $w_1 = u_1 a v_1$  und  $w_2 = u_2 b v_2$  zusammen mit  $|u_1| = |v_1|$  und  $|u_2| = |v_2|$

- Setze  $i \stackrel{\text{def}}{=} |u_1|$  und  $j \stackrel{\text{def}}{=} |u_2|$   $\boxplus$

$$\Rightarrow |w| = 2i + 1 + 2j + 1 = 2(i + j + 1)$$

- Das mittlere  $a$  von  $w_1$  ist an Position  $i + 1$  von  $1^{\text{st}}(w)$

- Das mittlere  $b$  von  $w_2$  ist in  $w$  an Position  $2i + 1 + j + 1 = (i + j + 1) + (i + 1)$

$\Rightarrow$  es ist in  $2^{\text{nd}}(w)$  an Position  $i + 1$

- Sei  $G_{\text{diff}}$  also die Grammatik

$$S \rightarrow AB \mid BA$$

$$A \rightarrow aAa \mid bAb \mid aAb \mid bAa \mid a$$

$$B \rightarrow aBa \mid bBb \mid aBb \mid bBa \mid b$$

### Satz 8.10

- $L(G_{\text{diff}}) = L_{\text{diff}}$

## Korrektheitsbeweise: $L_{\text{diff}}$ (2/3)

- Zur Illustration betrachten wir eine Ableitung des Strings  $w = \mathbf{abaaabba}$
- Aus  $A$  ist  $\mathbf{abaaa}$  ableitbar (mit  $\mathbf{a}$  in der Mitte)
- Aus  $B$  ist  $\mathbf{bba}$  ableitbar (mit  $\mathbf{b}$  in der Mitte)
- Also ist  $w$  ableitbar durch


$$S \Rightarrow AB \Rightarrow^* \mathbf{abaaa}B \Rightarrow^* \mathbf{abaaabba}$$

- Zu beachten:  $A$  erzeugt *nicht* die erste Hälfte von  $w$

## Korrektheitsbeweise: $L_{\text{diff}}$ (3/3)

### Beweisskizze

- Durch Induktion ist sehr leicht zu zeigen:
  - $L(A) = \{uav \mid |u| = |v|, u, v \in \{a, b\}^*\}$
  - $L(B) = \{ubv \mid |u| = |v|, u, v \in \{a, b\}^*\}$

 Hier bezeichnet  $L(A)$  die Menge der von der Variablen  $A$  ableitbaren Terminalstrings

$$\begin{aligned} \Rightarrow L(G_{\text{diff}}) = L(S) = \\ \{u_1av_1u_2bv_2 \mid |u_1|=|v_1|, |u_2|=|v_2|, \\ u_1, u_2, v_1, v_2 \in \{a, b\}^*\} \cup \\ \{u_1bv_1u_2av_2 \mid |u_1|=|v_1|, |u_2|=|v_2|, \\ u_1, u_2, v_1, v_2 \in \{a, b\}^*\} \end{aligned}$$

- Damit lässt sich  $L(G_{\text{diff}}) = L_{\text{diff}}$  recht einfach zeigen

 Anhang

# Zusammenfassung

- Jede kontextfreie Sprache hat eine Grammatik in Chomsky-Normalform, also nur mit Regeln der Art  $X \rightarrow YZ$  und  $X \rightarrow a$
- Jede kontextfreie Sprache hat eine Grammatik in Greibach-Normalform, also nur mit Regeln der Art  $X \rightarrow aY_1 \cdots Y_k$
- Außerdem kann jeweils noch eine Regel  $S \rightarrow \epsilon$  hinzukommen
  - dann darf  $S$  aber auf keiner rechten Seite vorkommen

# Literatur für dieses Kapitel

- **Chomsky-Normalform:**

- Noam Chomsky. On certain formal properties of grammars. *Information and Control*, 2(2):137–167, 1959

- **Greibach-Normalform:**

- Sheila A. Greibach. A new normal-form theorem for context-free phrase structure grammars. *J. ACM*, 12(1):42–52, 1965
- Norbert Blum and Robert Koch. Greibach normal form transformation revisited. *Inf. Comput.*, 150(1):112–118, 1999

# Inhalt

8.1 Chomsky-Normalform

8.2 Greibach-Normalform

8.3 Korrektheitsbeweise für kontextfreie Grammatiken

▷ **8.4 Anhang: Beweisdetails**

## CNF: (4) $\epsilon$ -Regeln entfernen

### Beweisskizze (Forts.)

- „ $X \Rightarrow_{G_4}^* w \Rightarrow X \Rightarrow_{G_3}^* w$ “:  
Wir zeigen:  

$$X \rightarrow_{G_4} Y \Rightarrow X \Rightarrow_{G_3}^* Y$$

☞ für jede neue Regel  $X \rightarrow Y$

  - Denn dann gibt es zu jeder Ableitung  $S \Rightarrow_{G_4}^* w$  eine Ableitung  $S \Rightarrow_{G_3}^* w$
- Sei also  $X \rightarrow Y$  neu in  $G_4$ 
  - 1. Fall:** In  $G_3$  gibt es eine Regel  $X \rightarrow YZ$  und  $Z \Rightarrow_{G_3}^* \epsilon$ 
    - Dann gilt:  

$$X \Rightarrow_{G_3} YZ \Rightarrow_{G_3}^* Y$$
  - 2. Fall:** In  $G_3$  gibt es eine Regel  $X \rightarrow ZY$  und  $Z \Rightarrow_{G_3}^* \epsilon$ 
    - Dann gilt:  

$$X \Rightarrow_{G_3} ZY \Rightarrow_{G_3}^* Y$$

### Beweisskizze (Forts.)

- „ $X \Rightarrow_{G_3}^* w \Rightarrow X \Rightarrow_{G_4}^* w$ “:
- Wir zeigen durch Induktion nach  $n$ :
  - $X \Rightarrow_{G_3}^n w \Rightarrow X \Rightarrow_{G_4}^* w$
- Es gelte also  $X \Rightarrow_{G_3}^n w$
- $n = 1$ :  $w = \sigma$  und  $X \rightarrow \sigma$  ist Regel von  $G_3$ , also auch von  $G_4$
- $n > 1$ :
  - **1. Fall:**  

$$X \Rightarrow_{G_3} YZ \Rightarrow_{G_3}^{n-1} w_1 w_2 = w$$

mit  $Y \Rightarrow_{G_3}^i w_1$ ,  $Z \Rightarrow_{G_3}^j w_2$  und  $i + j = n - 1$

    - \* Falls  $w_1 \neq \epsilon \neq w_2$  folgt die Behauptung per Induktion
    - \* Falls  $w_1 = \epsilon$ ,  $w_2 \neq \epsilon$ , so ist  $Y \in V'$   
 $\Rightarrow X \Rightarrow_{G_4} Z \Rightarrow_{G_4}^* w_2 = w$
    - \* (Analog:  $w_1 \neq \epsilon$ ,  $w_2 = \epsilon$ )
  - **2. Fall:**  $X \Rightarrow_{G_3} Y \Rightarrow_{G_3}^* w$ 
    - \* Induktion liefert:  $X \Rightarrow_{G_4} Y \Rightarrow_{G_4}^* w$

## CNF: (5) Einzel-Variablen der rechten Seite entfernen (3/3)

### Beweisskizze für Lemma 8.6

(b) klar

(a) „ $L(G_5) \subseteq L(G_4)$ “:

- Sei  $X \rightarrow \alpha$  eine gegenüber  $G_4$  neue Regel von  $G_5$
- ➔ In  $G_4$  gibt es dann eine Regel  $Y \rightarrow \alpha$ , für ein  $Y$ , und es gilt  $X \Rightarrow_{G_4}^* Y$
- ➔  $X \Rightarrow_{G_4}^* \alpha$
- ➔ Zu jeder Ableitung  $S \Rightarrow_{G_5}^* w$  gibt es also eine Ableitung  $S \Rightarrow_{G_4}^* w$

### Beweisskizze (Forts.)

- „ $L(G_4) \subseteq L(G_5)$ “:
  - Sei  $w \in L(G_4)$
  - Dann gibt es eine Linksableitung für  $w$  in  $G_4$
  - Wird in einer Linksableitung eine Einheitsregel  $X \rightarrow Y$  verwendet, so muss  $Y$  im nächsten Schritt wieder ersetzt werden
  - Nach endlich vielen Schritten muss dann zum ersten Mal eine Regel  $Z \rightarrow \alpha$  verwendet werden, die keine Einheitsregel ist
  - ➔  $X \Rightarrow_{G_4}^* Z$
  - ➔ Nach Konstruktion enthält  $G_5$  dann die Regel  $X \rightarrow \alpha$
  - ➔ Zu jeder  $G_4$ -Ableitung gibt es eine äquivalente  $G_5$ -Ableitung




# Details des Korrektheitsbeweises für $L_{\text{diff}}$

Beweisskizze: „ $L(G_{\text{diff}}) \subseteq L_{\text{diff}}$ “

- Sei  $w \in L(G_{\text{diff}})$
- 1. Fall:  $w = u_1 a v_1 u_2 b v_2$  für gewisse  $u_1, u_2, v_1, v_2 \in \{a, b\}^*$  mit  $|u_1| = |v_1|$  und  $|u_2| = |v_2|$ 
  - Sei  $i \stackrel{\text{def}}{=} |u_1|$  und  $j \stackrel{\text{def}}{=} |u_2|$
  - ➔  $|w| = 2i + 2j + 2$  und
    - \*  $w[i + 1] = a$
    - \*  $w[2i + j + 2] = b$
  - Wie schon berechnet ist dann
    - \*  $1^{\text{st}}(w) = a$
    - \*  $2^{\text{nd}}(w) = b$
  - ➔  $w \in L_{\text{diff}}$
- 2. Fall:  $w = u_1 b v_1 u_2 a v_2 \dots$ 
  - analog

Beweisskizze: „ $L_{\text{diff}} \subseteq L(G_{\text{diff}})$ “

- Sei  $w \in L_{\text{diff}}$  und  $n \stackrel{\text{def}}{=} |1^{\text{st}}(w)|$    $|w| = 2n$
- OBdA: gibt es ein  $i \in \{0, \dots, n - 1\}$ , so dass  $1^{\text{st}}(w)[i + 1] = a$  und  $2^{\text{nd}}(w)[i + 1] = b$
- Wir setzen:
  - $u_1 \stackrel{\text{def}}{=} w[1, i]$
  - $v_1 \stackrel{\text{def}}{=} w[i + 2, 2i + 1]$
  - $u_2 \stackrel{\text{def}}{=} w[2i + 2, n + i]$
  - $v_2 \stackrel{\text{def}}{=} w[n + i + 2, 2n]$
- ➔  $w = u_1 a v_1 u_2 b v_2$  und
  - $|u_1| = i = |v_1|$  und  $|u_2| = n + i - (2i + 2) + 1 = n - i - 1 = 2n - (n + i + 2) + 1 = |v_2|$
- ➔  $w \in L(G_{\text{diff}})$